

Derin Öğrenme Tabanlı Arka Plan Kaldırma Aracı:

U²-Net Mimarisi ile Görüntü Segmentasyonu

Şeyda Aytemür¹, Mehrdad Shomali²

2220656048@nku.edu.tr, 2210656637@nku.edu.tr

Tekirdağ Namık Kemal Üniversitesi, Çorlu Mühendislik Fakültesi, Tekirdağ, Türkiye

Github Bağlantısı: <https://github.com/seydaytemur/bg-remover-homework>

Görüntü İşleme Dersi - Proje Raporu

ÖZET

Bu çalışmada, karmaşık arka planlara sahip görüntülerden nesneleri yüksek hassasiyetle ayıran derin öğrenme tabanlı bir arka plan kaldırma aracı geliştirilmiştir. Geleneksel görüntü işleme yöntemlerinin (GrabCut, Canny kenar tespiti) düşük kontrastlı ve karmaşık sahnelerdeki yetersizlikleri göz önünde bulundurularak, anlamsal segmentasyon (semantic segmentation) yaklaşımı benimsenmiştir. Proje kapsamında U²-Net (U-Square-Net) derin öğrenme mimarisi kullanılmış ve rembg kütüphanesi ile entegre edilmiştir. Sistem, Python programlama dili ile geliştirilmiş; Pillow, CustomTkinter ve Threading teknolojileri kullanılarak kullanıcı dostu bir masaüstü uygulaması haline getirilmiştir. Geliştirilen araç, karmaşık detaylara (insan saçı, hayvan tüyü, şeffaf nesneler) sahip görüntülerde bile alpha matting tekniği sayesinde doğal kenar yumuşatma sağlamaktadır. Deneysel sonuçlar, önerilen sistemin karmaşık ışık koşullarında ve kalabalık arka planlarda yüksek doğrulukla çalıştığını göstermiştir.

Anahtar Kelimeler: Görüntü Segmentasyonu, Derin Öğrenme, U²-Net, Arka Plan Kaldırma, Alpha Matting, Salient Object Detection

1. GİRİŞ

Görüntü segmentasyonu, bilgisayarlı görü alanının temel problemlerinden biridir ve bir görüntüdeki nesneleri arka plandan ayırma işlemini ifade eder. Bu işlem, e-ticaret ürün fotoğrafçılığı, fotoğraf düzenleme, artırılmış gerçeklik uygulamaları, sanal arka plan sistemleri ve tıbbi görüntü analizi gibi birçok uygulama alanında kritik öneme sahiptir.

Geleneksel görüntü işleme yöntemleri, piksel yoğunluğu, renk dağılımı ve kenar tespiti gibi düşük seviye özelliklere dayanmaktadır. GrabCut algoritması gibi graf kesit (graph cut) tabanlı yöntemler ve Canny kenar tespiti gibi klasik yaklaşımlar, yalnızca renk (RGB) ve parlaklık kontrastını kullanarak segmentasyon yapmaktadır. Bu yöntemlerin temel sınırlaması, nesne ile arka plan arasında yeterli kontrast olmadığında (örneğin beyaz bir kedi ile beyaz duvar) veya karmaşık ışık koşullarında başarısız olmalarıdır.

Bu çalışmada, söz konusu sınırlamaları aşmak için derin öğrenme tabanlı bir yaklaşım benimsenmiş ve U²-Net mimarisi kullanılarak yüksek hassasiyetli bir arka plan kaldırma sistemi

geliştirilmiştir. Geliştirilen sistem, pikselleri anlamsal bağlamda analiz ederek, düşük kontrastlı ve karmaşık sahnelerde bile başarılı sonuçlar elde edebilmektedir.

2. PROBLEM TANIMI

2.1. Temel Sorun

Görüntülerde nesneyi arka plandan hassas bir şekilde ayırma (segmentation), özellikle aşağıdaki durumlar söz konusu olduğunda zorlu bir problemidir:

- Düşük kontrastlı sahneler: Nesne ve arka plan renginin benzer olduğu durumlar
- Karmaşık ışıklandırma: Gölge, parlama ve değişken ışık koşulları
- Karmaşık geometri: İnsan saç, hayvan tüyü, şeffaf nesneler gibi ince detaylar

2.2. Geleneksel Yöntemlerin Sınırları

OpenCV tabanlı GrabCut ve Canny kenar tespiti algoritmaları, sadece renk (RGB) ve parlaklık kontrastına odaklanmaktadır. Bu algoritmalar, nesne ile arka plan rengi benzeştiğinde (örneğin beyaz kedi - beyaz duvar senaryosu) nesneyi ayıramaz ve çökmektedir. Ayrıca, bu yöntemler ışık değişimlerine karşı oldukça hassastır ve sahnedeki gölge veya parlama gibi faktörler segmentasyon doğruluğunu ciddi şekilde düşürmektedir.

Proje hedefi, karmaşık ışık koşullarında ve kalabalık arka planlarda bile yüksek doğrulukla çalışan sağlam bir sistem tasarlamaktır.

3. ÇÖZÜM YAKLAŞIMI VE KULLANILAN TEKNOLOJİLER

3.1. Derin Öğrenme Yaklaşımı

Geleneksel yöntemlerin sınırlamalarını aşmak için, piksellerin anlamsal (semantic) bağlamını anlayabilen derin öğrenme (Deep Learning) yaklaşımı tercih edilmiştir. Derin öğrenme modelleri, milyonlarca etiketli görüntü üzerinde eğitilerek, bir pikselin sadece renk değerini değil, o pikselin hangi nesneye ait olduğunu öğrenebilmektedir.

3.2. U²-Net Mimarisi

Bu çalışmada, Salient Object Detection (SOD) alanında state-of-the-art (SOTA) kabul edilen U²-Net (U-Square-Net) mimarisi kullanılmıştır. U²-Net, rembg kütüphanesi ile entegre edilerek projeye dahil edilmiştir. U²-Net mimarisi, iç içe geçmiş (nested) yapısı sayesinde nesnenin hem lokal detaylarını (kenarlar, saç, tüy) hem de global bağlamını aynı anda öğrenebilmektedir.

U²-Net'in temel avantajı, yüksek çözünürlüklü özellik haritaları üreterek nesne sınırlarını kusursuz bir alpha maske olarak çıkarabilmesidir. Model, klasik U-Net mimarisinin encoder-decoder yapısını korurken, her seviyede kendi içinde bir U-Net bloğu barındırmaktadır. Bu iç içe yapı, farklı ölçeklerdeki özelliklerin etkili bir şekilde birleştirilmesini sağlamaktadır.

3.3. Kullanılan Teknolojiler

Proje geliştirme sürecinde kullanılan temel teknolojiler ve seçim nedenleri aşağıda sunulmuştur:

- **Python:** Görüntü işleme ve derin öğrenme ekosisteminin AI endüstri standardı olduğu için ana geliştirme dili olarak tercih edilmiştir.
- **Rembg (U²-Net):** Sıfırdan bir model yerine, milyonlarca görselle eğitilmiş (pre-trained) açık kaynaklı zirve nokta olan U²-Net modeli seçilmiştir.
- **Pillow (PIL):** Görüntü işleme ve manipülasyon için kullanılmıştır. Format dönüşümü ve EXIF rotasyon düzeltmeleri (ImageOps.exif_transpose) için tercih edilmiştir.
- **CustomTkinter:** Standart Tkinter yerine, modern Flat Design ve Dark Mode hissi veren estetik bir arayüz için kullanılmıştır.
- **Threading:** Kullanıcı arayüzünün donmasını engellemek ve arka planda asenkron işlem akışını sağlamak için kullanılmıştır.

4. U²-NET MİMARİSİ VE ÇALIŞMA PRENSİBİ

4.1. Mimari Özellikler

U²-Net (U-Square-Net) mimarisi, klasik U-Net yapısının geliştirilmiş bir versiyonudur. İç içe geçmiş (nested) yapısı sayesinde, nesnenin hem lokal detaylarını (kenarlar, saç telleri, hayvan tüyleri) hem de global bağlamını (nesnenin genel formu ve konumu) aynı anda öğrenebilmektedir.

Mimari, encoder-decoder yapısında olup, her encoder ve decoder bloğu kendi içinde bir U-Net yapısı barındırmaktadır. Bu sayede, farklı ölçeklerdeki özellikler etkili bir şekilde öğrenilmekte ve birleştirilmektedir. Sonuç olarak, yüksek çözünürlüklü özellik haritaları üretilerek nesne sınırları kusursuz bir alpha maske olarak çıkarılmaktadır.

4.2. Geleneksel Yöntemlerle Karşılaştırma

U²-Net, bir Salient Object Detection (SOD) modelidir ve pikselleri renk değil, anlamsal bağlamda inceler. Geleneksel yöntemlerden temel farkı, bir pikselin sadece RGB değerlerine bakmak yerine, o pikselin bir 'insan yüzü', 'hayvan', 'bitki' veya 'duvar' olup olmadığını derin öğrenme ile anlamasıdır.

Bu anlamsal analiz yeteneği sayesinde, arka plan ile nesne rengi benzeştiğinde bile (örneğin beyaz kedi - beyaz duvar senaryosu) model başarılı bir şekilde segmentasyon yapabilmektedir. Sonuç olarak, karmaşık ve düşük kontrastlı ortamlarda dahi kusursuz segmentasyon sağlanmaktadır.

5. TEKNİK ZORLUKLAR VE GELİŞTİRİLEN ÇÖZÜMLER

5.1. Memory Leak (RAM Taşması) Sorunu

Proje geliştirme sürecinde karşılaşılan ilk teknik zorluk, yüksek çözünürlüklü (4K) veya üst üste yüklenen görsellerin sistemi dondurucu seviyede RAM tüketimine neden olmasıydı. Bu problem, özellikle sınırlı donanıma sahip kullanıcılar için kritik bir performans engeliydi.

Çözüm olarak, görseller maksimum 2000 piksel boyutuna (max_dim=2000px) Lanczos algoritması ile dinamik olarak ölçeklendirilmiştir (downscaling). Lanczos algoritması, yüksek

kaliteli yeniden örnekleme sağladığı için görsel kalite kaybı minimum düzeyde tutulmuştur. Bu optimizasyon, uygulamanın farklı donanımlarda stabil çalışmasını sağlamıştır.

5.2. Görsel Yönelim (Orientation) Hatası

İkinci önemli teknik sorun, akıllı telefonlarla çekilen dikey fotoğrafların programa yüklendiğinde yatay olarak görüntülenmesiydi. Bu durum, EXIF meta verilerinde saklanan rotasyon bilgisinin yazılım tarafından dikkate alınmamasından kaynaklanmaktaydı.

Sorun, Pillow kütüphanesinin ImageOps.exif_transpose fonksiyonu kullanılarak çözülmüştür. Bu fonksiyon, EXIF verilerini okuyarak görselin doğru yönelimde görüntülenmesini sağlamaktadır. Bu çözüm, kullanıcı deneyimini önemli ölçüde iyileştirmiştir.

5.3. Alpha Matting ile Kenar Yumuşatma

İnsan saç, hayvan tüyü veya şeffaf nesnelerin (gözlük camı gibi) kenarlarında doğal olmayan sert geçişlerin oluşması, görüntü segmentasyonunun klasik bir problemidir. Siyah-beyaz kesin bir maske kullanılması, bu tür ince detaylarda yapay görünüm oluşturur.

U²-Net modeli, sadece 'Siyah-Beyaz' kesin bir maske yerine, piksellerin şeffaflık (transparency) değerlerini hesaplayarak alpha matting tekniği ile arka planı pürüzsüzce silmektedir. Bu sayede, kenar geçişleri doğal görünmekte ve profesyonel sonuçlar elde edilmektedir.

6. KULLANICI ARAYÜZÜ TASARIMI VE DENEYİMİ

6.1. Modern UI Tasarımı

Kullanıcı arayüzü tasarımında, standart Tkinter yerine CustomTkinter kütüphanesi kullanılmıştır. Bu tercih, Flat Design prensiplerine uygun, Dark Mode destekli ve modern bir görünüm sağlamaktadır. Arayüz, kullanıcı deneyimini ön planda tutacak şekilde sade ve anlaşılır bir yapıda tasarlanmıştır.

6.2. Asenkron İşlem Yönetimi

Yapay zeka motoru ve kullanıcı arayüzü farklı Thread'lerde çalıştırılarak, model işleme sırasında uygulamanın donması (Not Responding) engellenmektedir. Threading kullanımı, kullanıcının görsel işleme sürecinde arayüz ile etkileşimde kalabilmesini sağlamak ve genel kullanım deneyimini önemli ölçüde iyileştirmektedir.

7. MODEL DEĞERLENDİRME METODOLOJİSİ

7.1. Değerlendirme Zorluğu

Arka plan kaldırma sistemlerinin objektif değerlendirilmesi, spesifik ve önceden etiketlenmiş bir Ground Truth veri setinin varlığını gerektirmektedir. Ancak bu proje kapsamında, kullanılan spesifik görsel türleri (kürk, saç, şeffaf nesneler gibi zorlu kenar örnekleri) için hazır bir Ground Truth veri seti bulunmamaktaydı. Bu durum, model başarımının güvenilir bir şekilde ölçülmesinde önemli bir zorluk oluşturmıştır.

7.2. Pseudo-Ground Truth Metodolojisi

Ground Truth veri seti eksikliğini gidermek için Pseudo-Ground Truth metodolojisi geliştirilmiştir. Bu yaklaşımda, literatürde yüksek başarısı kanıtlanmış ağır ve hesaplama maliyeti yüksek olan isnet-general-use modeli referans model olarak seçilmiştir. Bu model kullanılarak test görüntüleri için referans maskeler (pseudo-ground truth) üretilmiş ve projede kullanılan hafif u2net modelinin çıktıları bu referans maskeler ile matematiksel olarak karşılaştırılmıştır.

Bu yaklaşım, mutlak doğruluk garanti etmemekle birlikte, endüstride yaygın kabul gören bir model ile göreceli performans ölçümü yapılmasına olanak tanımıştır. Böylece sistemin başarımı, rastgele değil bilimsel bir referansa dayalı olarak değerlendirilmiştir.

7.3. Test Verisi Seçimi

Model değerlendirmesi için özellikle zorlu kenar (hard edge) özelliklerine sahip 7 farklı görsel seçilmiştir. Bu görseller şunları içermektedir:

- Hayvan kürkü ve tüyleri: İnce, saydam ve çok sayıda keskin kenar
- İnsan saçı: Dağınık ve farklı yönlerdeki saç telleri
- Bisiklet tekerlekleri: İnce tellerden oluşan karmaşık iç boşluklar
- Şeffaf nesneler: Gözlük camı gibi kısmi geçirgenliğe sahip materyaller

8. KANTİTATİF SONUÇLAR VE PERFORMANS METRİKLERİ

8.1. Kullanılan Metrikler

Model başarısını ölçmek için görüntü segmentasyonu literatüründe kabul gören iki temel metrik kullanılmıştır:

IoU (Intersection over Union): Tahmin edilen maskenin referans maske ile kesişim alanının, birleşim alanına oranıdır. Formül: $IoU = (Tahmin \cap Gerçek) / (Tahmin \cup Gerçek)$. Bu metrik, segmentasyon doğruluğunun genel bir ölçüsünü sağlar. Değer aralığı [0,1] olup 1 mükemmel örtüşmeyi gösterir.

F1-Score (Dice Katsayısı): Precision (kesinlik) ve Recall (duyarlılık) değerlerinin harmonik ortalamasıdır. Formül: $F1 = 2 \times (Precision \times Recall) / (Precision + Recall)$. Bu metrik, özellikle dengesiz veri setlerinde daha güvenilir sonuçlar verir. Değer aralığı [0,1] olup 1 en yüksek başarıyı ifade eder.

8.2. Genel Başarım Sonuçları

7 farklı zorlu kenar görseli üzerinden yapılan kapsamlı analiz sonucunda elde edilen kantitatif sonuçlar aşağıda sunulmuştur:

- **Mean IoU (Ortalama Kesişim/Birleşim):** %90.92
- **Mean F1-Score (Ortalama Kesinlik):** %94.59

Bu sonuçlar, hafifletilmiş U²-Net mimarisinin ağır referans modele kıyasla neredeyse %95'e yakın bir genel başarı sergilediğini göstermektedir. Model, özellikle kürk, saç ve düz kenarlı nesnelerde çok yüksek performans göstermiştir.

8.3. Performans Analizi ve Zayıf Noktalar

Detaylı analiz sonucunda, modelin bazı spesifik senaryolarda doğruluk düşüşü yaşadığı tespit edilmiştir. Özellikle karmaşık iç boşluklara sahip objeler (bisiklet telleri, tel örgü, kafes yapıları gibi) segmentasyon zorluğu yaratmaktadır. Bu durum, ince ve saydam yapıların alpha matting ile tam olarak çözilememesinden kaynaklanmaktadır.

Bununla birlikte, genel kullanım senaryolarında (portre fotoğrafları, ürün fotoğrafçılığı, evcil hayvan görselleri) model %90'ın üzerinde bir başarı oranı sunmaktadır ve pratik uygulamalar için yeterli doğruluk seviyesindedir.

9. NİTELİKSEL ANALİZ VE ALPHA MATTING ETKİSİ

9.1. Zorlu Kenar Testleri

Modelinin kürk, saç ve şeffaf objelerdeki performansını artırmak için Alpha Matting (Kenar Yumuşatma) filtresi sisteme opsiyonel olarak entegre edilmiştir. Alpha Matting, keskin binary segmentasyon yerine piksel düzeyinde şeffaflık değerleri hesaplayarak daha doğal geçişler sağlamaktadır.

9.2. Görsel Karşılaştırma ve Gözlemler

Alpha Matting özelliğinin görsel etkisi detaylı olarak analiz edilmiştir:

Alpha Matting Kapalı: Segmentasyon çıktısında keskin ve kopuk saç teli/tüy detayları gözlemlenmiştir. Özellikle ince tüylerin uçlarında sert kesimler ve doğal olmayan kenarlar oluşmaktadır. Bu durum, görselin yapay bir görünüm kazanmasına neden olmaktadır.

Alpha Matting Açık: Filtre aktif edildiğinde, saç telleri ve kürk geçişlerinde doğal bir yumuşama elde edilmiştir. Kenarlar pürüzsüz ve gerçekçi görünmekte, ince detaylar korunmaktadır. Sonuç görseller, profesyonel fotoğraf düzenleme yazılımlarından elde edilen çıktılara yakın kalitededir.

9.3. Performans Maliyeti Analizi

Alpha Matting özelliğinin hesaplama maliyeti ölçülmüştür. Normal işlem süresi ortalama ~1 saniye sürerken, Alpha Matting aktif edildiğinde bu süre ~3.5-4 saniyeye çıkmaktadır. Bu yaklaşık 3.5-4 kat performans düşüşü, özelliğin opsiyonel olarak sunulmasını gerektirmiştir. Kullanıcılar, hız ve kalite arasındaki dengeyi kendi ihtiyaçlarına göre ayarlayabilmektedir.

10. PERFORMANS ÖLÇEKLEMESİ VE HIZLANDIRMA

10.1. Çözünürlük Bazlı Performans Testleri

Gerçek dünya kullanımında, kullanıcılar farklı çözünürlüklerde görseller yükleyebilmektedir. Yüksek çözünürlüklü (4K ve üzeri) fotoğrafların RAM/VRAM taşmalarına yol açmaması için akıllı ölçekleme mekanizması geliştirilmiştir. Sistemin farklı çözünürlüklerdeki performansını ölçmek için aynı görsel üç farklı boyuta ölçeklenerek test edilmiştir:

- 500x500 piksel (SD çözünürlük): ~0.7 saniye
- 1000x1000 piksel (HD çözünürlük): ~0.8 saniye

- **2000x2000 piksel (2K+ çözünürlük):** ~0.9 saniye

Bu sonuçlar, uygulamanın çözünürlük artsa dahi algoritmik koruma sayesinde 1 saniyenin altında tutarlı bir işlem hızı sunduğunu göstermektedir. Dinamik ölçekleme algoritması, görsel kalitesinden ödün vermeden yüksek performans sağlamaktadır.

10.2. Ölçeklenebilirlik ve Optimizasyon

Geliştirilen akıllı ölçekleme mekanizması, görselleri işlem öncesinde maksimum 2000 piksel boyutuna indirerek hem hız hem de bellek tüketimi açısından optimum sonuçlar elde etmektedir. Lanczos yeniden örnekleme algoritması kullanılarak görsel kalite kaybı minimum düzeyde tutulmaktadır. Bu yaklaşım sayesinde uygulama, farklı donanım kapasitelerine sahip kullanıcılara tutarlı bir deneyim sunabilmektedir.

11. KULLANICI ARAYÜZÜ TASARIMI VE DENEYİMİ

7.1. Model Başarımı

Geliştirilen arka plan kaldırma aracı, çeşitli test senaryolarında yüksek performans göstermiştir. Özellikle evcil hayvan tüyleri gibi karmaşık detaylarda dahi yüksek hassasiyetle çalışmaktadır. Gözlemler şu şekilde özetlenebilir:

- Keskin kenar ayrımı: Nesne sınırları net bir şekilde tespit edilmekte ve ayrıştırılmaktadır.
- Işık ve gölge uyumu: Farklı ışık koşullarında tutarlı sonuçlar elde edilmektedir.
- Hızlı işleme süresi: Model optimizasyonu sayesinde kabul edilebilir işleme süreleri sağlanmaktadır.

7.2. Karmaşık Arka Plan Segmentasyonu

Yapay zeka motoru, kalabalık arka planlarda dahi ana objeyi hatasız bir şekilde tespit ederek başarılı bir ayrıştırma sağlamaktadır. Test senaryolarında, karmaşık arka plan segmentasyonu, yüksek doğrulukta obje maskeleye ve gerçek zamanlı görsel önizleme özellikleri başarıyla gösterilmiştir.

8. SONUÇ VE GELECEK ÇALIŞMALAR

8.1. Sonuç

Bu çalışmada, U²-Net mimarisi kullanılarak geleneksel yöntemlerin yetersiz kaldığı kısıtlanmamış (unconstrained) ve karmaşık ortamlarda üstün başarı sağlayan bir arka plan kaldırma sistemi geliştirilmiştir. Proje, kullanıcı dostu ve sorunsuz çalışan bir masaüstü uygulamasına dönüştürülmüş ve çeşitli teknik zorluklara özgün çözümler geliştirilmiştir.

Derin öğrenme tabanlı yaklaşım, anlamsal segmentasyon sayesinde düşük kontrastlı sahnelerde bile yüksek doğrulukla çalışabilmektedir. Alpha matting tekniği ile elde edilen doğal kenar yumuşatması, profesyonel düzeyde sonuçlar üretmektedir.

8.2. Gelecek Çalışmalar

Sistemin gelecek versiyonlarında aşağıdaki özellikler eklenebilir:

- **Toplu İşlem (Batch Processing):** Birden fazla görselin tek seferde yüklenmesi ve işlenmesi özelliği eklenebilir. Bu sayede, kullanıcılar büyük miktarda görsel üzerinde toplu işlem yapabileceklerdir.
- **Arka Plan Değiştirme:** Silinen arka planın yerine dinamik manzara resimleri veya renk gradyanları ekleme özelliği geliştirilebilir. Bu özellik, özellikle e-ticaret ve sosyal medya kullanımları için değerli olacaktır.
- **Model Optimizasyonu:** Daha hızlı çalışma süreleri için model kuantizasyonu ve optimizasyonu yapılabilir.
- **Web Tabanlı Versiyon:** Masaüstü uygulamasının yanı sıra, web tabanlı bir versiyon geliştirilerek erişilebilirlik artırılabilir.

KAYNAKLAR

- [1] Qin, X., Zhang, Z., Huang, C., Dehghan, M., Zaiane, O. R., & Jagersand, M. (2020). U²-Net: Going deeper with nested U-structure for salient object detection. *Pattern Recognition*, 106, 107404.
- [2] Rother, C., Kolmogorov, V., & Blake, A. (2004). GrabCut: Interactive foreground extraction using iterated graph cuts. *ACM Transactions on Graphics (TOG)*, 23(3), 309-314.
- [3] Canny, J. (1986). A computational approach to edge detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, (6), 679-698.
- [4] Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. *International Conference on Medical Image Computing and Computer-Assisted Intervention*, 234-241.
- [5] Levin, A., Lischinski, D., & Weiss, Y. (2008). A closed-form solution to natural image matting. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 30(2), 228-242.
- [6] Zhang, X., Wang, T., Qi, J., Lu, H., & Wang, G. (2018). Progressive attention guided recurrent network for salient object detection. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 714-722.